

Análisis de Modelos para Describir Imágenes

Comparación de BLIP, ViT-GPT2 y Gemini 2.5 Pro

Resumen

Este informe analiza tres modelos que generan descripciones automáticas de imágenes: BLIP (de Salesforce), ViT-GPT2 (de nlpconnect) y Gemini 2.5 Pro (de Google). Se evalúa qué tal funcionan, sus limitaciones, qué tan rápidos son y en qué situaciones usar cada uno.

1. Introducción

El proyecto usa tres modelos diferentes para describir imágenes automáticamente. Cada modelo funciona de forma independiente usando Docker, lo que hace fácil comparar sus resultados.

El sistema es simple: toma imágenes de la carpeta `img/` y guarda las descripciones en archivos de texto en la carpeta `outputs/`. Así se pueden revisar los resultados de cada modelo sin complicaciones.

2. Los Tres Modelos Elegidos

Se eligieron tres modelos muy diferentes entre sí. Cada uno tiene características que los hacen útiles en distintas situaciones.

2.1. BLIP

BLIP fue creado por Salesforce. Combina dos tecnologías: un Vision Transformer que analiza las imágenes y un modelo de lenguaje parecido a BERT que genera el texto. Tiene unos 224 millones de parámetros, lo que lo hace mediano en tamaño.

Tiene un buen balance entre calidad y velocidad. Fue entrenado específicamente para describir imágenes, así que es muy bueno en eso. Muchas empresas y universidades lo usan, y es fácil de integrar usando Hugging Face Transformers.

2.2. ViT-GPT2

Este modelo también combina dos partes: Vision Transformer para ver las imágenes y GPT-2 para escribir las descripciones. Tiene unos 150 millones de parámetros, siendo el más pequeño de los tres.

Se incluye porque es más ligero y rápido. Funciona bien cuando no tienes mucha potencia de computación, como en aplicaciones móviles.

2.3. Gemini 2.5 Pro

Gemini es el modelo más avanzado de Google. Puede procesar imágenes, texto y código. A diferencia de los otros dos, no lo ejecutas en tu computadora sino que usas su API en la nube.

Lo incluimos para tener una referencia de máxima calidad. Genera descripciones mucho más detalladas y naturales que los otros. Otra ventaja es que entiende instrucciones en español, así podemos controlar mejor cómo describe las imágenes. También nos ayuda a comparar si vale la pena pagar por un servicio vs usar modelos gratuitos.

3. Cómo Funciona Cada Modelo

3.1. Lo que genera cada uno

BLIP hace descripciones cortas y directas. Normalmente escribe entre 5 y 15 palabras que capturan lo esencial de la imagen. Por ejemplo, para una foto de alguien en la playa, BLIP diría algo como "una persona parada en una playa cerca del océano". Funciona muy bien con escenas normales, objetos comunes y actividades cotidianas.

ViT-GPT2 crea descripciones parecidas a BLIP pero usa menos variedad de palabras. Las frases tienden a repetirse más y ser más predecibles. Tiene problemas con escenas complicadas. Su ventaja es que es más rápido que BLIP.

Gemini 2.5 Pro es mucho mejor en calidad. Las descripciones son más largas y detalladas, no solo dice qué hay en la imagen sino también las relaciones entre las cosas. Por ejemplo, donde BLIP diría "un perro en un parque", Gemini diría "un perro golden retriever jugando en un parque soleado mientras su dueño observa desde un banco cercano".

3.2. Control sobre las descripciones

Aquí hay una diferencia importante. BLIP y ViT-GPT2 no permiten darles instrucciones. Les das una imagen y ellos generan una descripción, punto. No puedes pedirles que sean más detallados o que se enfoquen en algo específico.

Gemini sí permite control total. En el código usamos esta instrucción: "Proporciona UNA sola descripción breve y clara que describa la imagen. Devuelve únicamente un párrafo corto descriptivo." Si quisiéramos descripciones técnicas, poéticas o enfocadas en algo específico, solo cambiamos esa instrucción.

4. Qué Funciona Mejor en Cada Caso

4.1. Según el tipo de imagen

Los modelos funcionan diferente según qué tipo de imagen les muestres.

Escenas cotidianas como gente haciendo actividades normales o paisajes funcionan excelente con BLIP y Gemini. ViT-GPT2 funciona bien pero es menos consistente. Este es el mejor caso para los tres porque vieron muchas imágenes así durante su entrenamiento.

Objetos específicos como productos: BLIP funciona bien en general, pero puede fallar con cosas muy técnicas. ViT-GPT2 tiende a ser vago (dice "un objeto en una mesa" en vez de decir qué objeto es). Gemini es el mejor aquí, puede identificar marcas y modelos específicos.

Escenas abstractas o artísticas son más difíciles. BLIP describe lo básico pero no capta el concepto abstracto. ViT-GPT2 da descripciones muy genéricas. Gemini lo hace mejor pero tampoco es perfecto.

4.2. Fortalezas y debilidades de cada uno

BLIP es bueno para descripciones balanceadas de imágenes comunes. Reconoce bien actividades humanas típicas y escenas con varios objetos. Sus problemas: objetos técnicos especializados, contextos culturales específicos, y no detecta texto.

ViT-GPT2 destaca por ser rápido y eficiente. Sus problemas: menos variedad en las palabras que usa, descripciones más genéricas, y rinde peor en escenas complejas.

Gemini 2.5 Pro hace las mejores descripciones de los tres. Puede leer texto en imágenes, entiende conceptos abstractos y relaciones complejas. Puedes controlarlo con instrucciones. Sus problemas: cuesta dinero usarlo, necesita Internet, es más lento que los modelos locales, y dependes de Google.

5. Limitaciones del Proyecto

5.1. Problemas de los modelos

Alucinaciones: A veces los modelos describen cosas que no están en la imagen. Esto pasa especialmente en escenas confusas o cuando parte de un objeto está oculto. Por ejemplo, si ve parte de lo que podría ser una bicicleta, podría describir una bicicleta completa aunque solo se vea una rueda.

Descripciones genéricas: Los modelos gratuitos tienden a dar descripciones muy generales que omiten detalles importantes. Para diagnóstico médico, análisis forense o control de calidad industrial estos modelos no son suficientemente precisos sin entrenamiento adicional.

No entienden secuencias: Ninguno de los modelos puede analizar varias imágenes en secuencia. Si necesitas describir cómo cambia algo entre dos fotos, estos modelos no pueden hacerlo.

5.2. Problemas del proyecto actual

Sin evaluación automática: No hay métricas que calculen automáticamente qué tan buenas son las descripciones. Todo se tiene que revisar manualmente.

Sin referencias para comparar: El sistema procesa imágenes sin tener descripciones correctas de referencia. No podemos saber si los modelos están funcionando a su nivel óptimo.

Sin optimización: Los modelos usan la configuración por defecto. No están optimizados para velocidad o calidad específica del proyecto.

6. Velocidad y Uso Práctico

6.1. Tiempo que tarda cada modelo

Estos son los tiempos aproximados cuando usas solo CPU (sin tarjeta gráfica):

BLIP: entre 8 y 15 segundos por imagen. Es lento para procesar muchas imágenes, pero aceptable si un usuario sube fotos de vez en cuando.

ViT-GPT2: entre 5 y 10 segundos por imagen. Es más rápido que BLIP, lo que hace diferencia cuando procesas cientos o miles de imágenes.

Gemini: entre 2 y 5 segundos por imagen, pero esto incluye el tiempo de enviar la imagen por Internet a los servidores de Google. Con Internet rápido puede ser el más veloz, con Internet lento puede ser el más tardado.

Estos tiempos son para imágenes de tamaño normal (224x224 a 512x512 píxeles). Imágenes más grandes tardan más.

6.3. Qué necesitas para usarlos

Para BLIP y ViT-GPT2: como mínimo una computadora con 4 núcleos de CPU y 8GB de RAM. Funcionarán pero lento. Es mejor tener una tarjeta gráfica NVIDIA con 4GB de memoria (como GTX 1660 o RTX 3050), esto los hace muchos más rápidos.

Para Gemini: solo necesitas Internet y una clave de API. Funciona en cualquier computadora, incluso laptops baratas o celulares. La limitación no es tu hardware sino el costo de usar la API de Google.

7. Conclusiones

7.1. Cuál modelo elegir

No hay un modelo que sea el mejor para todo. Depende de qué necesites.

BLIP y ViT-GPT2 necesitas buen balance entre calidad y costo, quieres procesar imágenes localmente sin pagar APIs

Gemini: necesitas la mejor calidad posible, requieres leer texto en imágenes con el coste adicional que supone.